

Phase 1 : Sélection du Dataset

1. Présentation générale du dataset

Nom du dataset : Healthcare Dataset

Source : Kaggle

URL : <https://www.kaggle.com/datasets/prasad22/healthcare-dataset>

Ce projet s'appuie sur un dataset public issu de la plateforme Kaggle, représentant des données hospitalières et médicales liées aux patients, à leur admission et à leur prise en charge médicale.

Le dataset contient des informations critiques typiques d'un système d'information hospitalier, telles que les caractéristiques des patients, les dates d'admission et de sortie, les traitements médicaux, les établissements de santé et les montants de facturation.

Ce type de données est particulièrement pertinent pour une étude de qualité des données et de gouvernance, dans la mesure où le domaine de la santé impose des exigences élevées en matière de fiabilité, de cohérence et de traçabilité des données.

2. Description métier et contexte business

Dans un contexte hospitalier, les données patients jouent un rôle central dans :

- + la prise de décision médicale,
- + la gestion opérationnelle des établissements de santé,
- + la facturation et les relations avec les assureurs,
- + ainsi que la conformité réglementaire (qualité des soins, audits, reporting).

Des données de mauvaise qualité peuvent entraîner :

- + des erreurs de facturation,
- + des incohérences dans les dossiers médicaux,
- + des problèmes de suivi des patients,
- + et des risques importants en matière de gouvernance et de confiance dans les systèmes d'information.

Le dataset sélectionné simule une table opérationnelle contenant des données issues de différents processus métiers (admission, soins, facturation), ce qui en fait un excellent candidat pour une démarche complète d'audit de qualité des données, de nettoyage, de validation automatisée et de monitoring continu.

3. Description technique et statistiques globales

Structure du dataset

- + Nombre de lignes : 55 500
- + Nombre de colonnes : 15
- + Taille mémoire : ~6,4 MB

Types de données

Variables numériques :

- + *Age* : int
- + *Billing Amount* : float
- + *Room Number* : int

Variables catégorielles (object) :

- + *Name*
- + *Genre*
- + *Blood Type*
- + *Medical Condition*
- + *Date of Admission*
- + *Doctor*
- + *Hospital*
- + *Insurance Provider*
- + *Admission Type*
- + *Discharge Date*
- + *Medication*
- + *Test Results*

Liste des principales colonnes

Informations patient : *Name, Age, Gender, Blood Type*

Informations médicales : *Medical Condition, Medication, Test Results*

Informations hospitalières : *Doctor, Hospital, Room Number*

Informations administratives : *Insurance Provider, Admission Type*

Informations financières : *Billing Amount*

Dates clés : *Date of Admission, Discharge Date*

L'analyse préliminaire montre que 100 % des champs sont renseignés, ce qui constitue un indicateur positif de complétude. Toutefois, l'absence de valeurs manquantes ne garantit pas à elle seule la qualité globale des données, d'où la nécessité d'une analyse approfondie des autres dimensions de la qualité.

4. Justification du choix du dataset

Le choix de ce dataset est motivé par plusieurs éléments clés :

- Conformité aux critères du projet
 - + Dataset réel issu d'une source publique reconnue
 - + Volume de données suffisant (> 50 000 lignes)
 - + Diversité des types de données (numérique, textuel, dates)
 - + Contexte métier clair et documentable

- Le domaine de la santé est particulièrement sensible aux problématiques de gouvernance des données, notamment en matière de :
 - + traçabilité des informations
 - + fiabilité des indicateurs
 - + documentation des règles de gestion
 - + contrôle continu de la qualité

Ce dataset offre ainsi un cadre réaliste pour la mise en place d'une architecture de Data Quality, incluant validation automatisée, indicateurs de suivi et documentation métier.

5. Conclusion

En résumé, le dataset Healthcare Dataset représente un choix idéal pour ce projet. Il combine un volume conséquent de données, une diversité de types de variables et un contexte métier concret et documenté. Ces caractéristiques permettent de mettre en œuvre efficacement une démarche complète de Data Quality, couvrant tous les piliers essentiels et facilitent l'instauration d'une gouvernance des données robuste. Ainsi, ce dataset constitue un support réaliste et pertinent pour l'audit, le nettoyage, la validation et le monitoring des données, tout en respectant les exigences académiques et professionnelles.