

Phase 2 : Profilage et Exploration

Dans cette phase, nous procédons au profilage et à l'exploration de nos données afin d'en détecter les anomalies.

- 1) Premièrement , nous allons faire un bref rappel concernant la description de notre dataset et comment on le récupère.
- 2) Dans un second temps , nous réaliserons une analyse de santé globale automatisée grâce à la librairie **Sweetviz**.
Script : **01_Profilage_Exploration_automatisée.ipynb**
- 3) Troisièmement, nous mènerons une exploration manuelle approfondie pour identifier les incohérences métier plus complexes.
Script : **02_Profilage_Exploration_manuelle.ipynb**.
- 4) Enfin, nous présenterons une matrice d'impact métier général et un plan de redressement général priorisé. Cette étape fondamentale vise à clarifier les règles de nettoyage qui seront appliquées par la suite.

1. Rappel sur la structure du dataset


Comme indiqué précédemment , notre dataset *healthcare_dataset.csv* contient des informations médicales . Pour réaliser les analyses, nous commençons par récupérer les fichiers CSV. Ces fichiers sont ensuite stockés dans une table nommée **healthcare_bronze**. Cette table est créée via le script **01_Profilage_Exploration_automatisée.ipynb**. L'ensemble des analyses de la phase 2 sera effectué en utilisant les données contenues dans cette table.

- Avec la structure suivante :
 - + *Nombre de lignes* : 55 500
 - + *Nombre de colonnes* : 15
 - + *Taille mémoire* : ~6,4 MB
- Et les colonnes suivantes :
 - + *Object* : Name ,Genre ,Blood Type, Medical Condition ,Doctor , Hospital, Insurance Provider, Admission Type , Medication, Date of Admission , Discharge Date , Test Results
 - + *Integer* : Age , Room Number
 - + *Float* : Billing Amount

2. État de santé globale du dataset automatisée

2.1 Statistique globale

Les analyses faites dans cette partie sont issues des résultats que nous avons obtenus grâce au profilage automatisé avec Sweetviz et **01_Profilage_Exploration_automatisée.ipynb**.



Capture 1: Résultat de l'analyse globale du dataset

- + On voit sur cette image globale que nos données contiennent 55 500 lignes ce qui est cohérent.
- + On voit que la base de données présente 534 doublons.
- + Les 15 features correspondent aux 15 colonnes.
- + On voit qu'il existe 7 colonnes qui sont de type categorial , 3 colonnes de type numérique , et 5 colonnes de types textes .

Cette première statistique globale montre déjà qu'on a des anomalies au niveau des types des colonnes. Car d'après le contenu du dataset , il devrait y avoir 10 colonnes de type string ou object , 2 colonnes de type integer , 1 colonne de type float et 2 colonnes de type date.

2.2 Analyse approfondie

a) Exactitude et Fomat :

Anomalie Détectée	Colonnes Concernées	Exemples Concrets / Preuves	Impact Projet
Casse Aléatoire (Random Case)	Name	DAvId muNoZ, teRRY gONZaLeZ (Mélange anarchique de majuscules/minuscules)	CRITIQUE. Empêche les jointures, le tri alphabétique et nuit à l'image de marque (mailing).

Pollution par Titres	Name	Dr. David, Mr. John, PhD, MD , (<i>Titres mélangés au nom propre</i>)	Fausse l'identification. "David" et "Dr. David" sont vus comme 2 personnes différentes.
Nomenclature Incorrecte	Hospital	Smith LLC, Johnson Inc, PLC (<i>Suffixes d'entreprises commerciales au lieu de médicaux</i>)	Perte de crédibilité. Un hôpital n'est pas une "LLC" (Société Limitée).
Doublons Sémantiques	Doctor	Michael Smith vs Michael Smith (espace en trop probable)	Difficulté à calculer la performance par médecin.

→ Exemple d'illustrations d'après l'analyse sur sweetviz :


Colonne Name : présence d'un préfixe et suffixe pour “*dr. anThoNy wILsoN dVM*”



Name		
MISSING: ---		
3	<1%	DAvid muNoZ
2	<1%	SOmYa aDams
2	<1%	terRY gONZaLeZ
2	<1%	JaCKsON BaRBeR
2	<1%	doNALD aVILA
2	<1%	RIChARd cHERry
2	<1%	Jeffrey davis
2	<1%	BrEAnNA JaMeS
2	<1%	MEgan mORRison
2	<1%	kaTheRine WeBSTER
2	<1%	MaTthew TyleR
2	<1%	edWaRd boYd
2	<1%	dr anThoNy wILsoN dVM
2	<1%	PaUl PaYNE
2	<1%	BriAn baRRETT

Capture 3 : Résultat d'analyse approfondie de la colonne Name

Colonne Hospital : apparition de suffixe “*LLC*”



Hospital		
MISSING: ---		
44	<1%	LLC Smith
39	<1%	Ltd Smith
38	<1%	Johnson PLC
37	<1%	Smith Ltd
36	<1%	Smith PLC
36	<1%	Smith Group
35	<1%	Johnson Inc
34	<1%	Smith Inc
32	<1%	Smith LLC
32	<1%	Group Smith
30	<1%	LLC Johnson
30	<1%	PLC Williams
29	<1%	PLC Smith
28	<1%	Inc Brown
28	<1%	Brown Inc
27	<1%	Inc Smith
27	<1%	Johnson Group
26	<1%	Inc Johnson
26	<1%	Group Johnson
25	<1%	Williams LLC

Capture 5 : Résultat d'analyse approfondie de la colonne Hospital

b) Validité :

Anomalie Détectée	Colonnes Concernées	Exemples Concrets / Preuves	Impact Projet
Valeurs Aberrantes	Billing Amount	-2 008,49 \$ (Valeur Négative)	BLOQUANT. Fausse la comptabilité totale. Un hôpital ne paie pas le patient.
Incohérence Légale	Age	Patients de 13, 14, 15 ans présents comme "clients" principaux.	Un mineur ne peut pas être facturé directement. Problème juridique majeur.
Impossibilité Statistique	Blood Type	AB- (très rare) est aussi fréquent que O+ (très courant). Répartition plate (~12.5%).	Gestion des stocks de sang impossible (Pénurie de O+ garantie).
Liste Incomplète	Medication	Seulement 5 médicaments (<i>Aspirin, Penicillin...</i>) pour tout l'hôpital.	Manque d'Insuline (Diabète), Chimio (Cancer), Ventoline (Asthme).

→ Exemple d'illustrations d'après l'analyse sur sweetviz :

SMALLEST VALUES		
-2008.492...	1	<0.1%
-1660.009...	1	<0.1%
-1520.420...	1	<0.1%
-1428.843...	1	<0.1%
-1316.618...	2	<0.1%
-1310.272...	2	<0.1%
-1306.662...	1	<0.1%
-1277.645...	1	<0.1%
-1129.997...	1	<0.1%
-1049.012...	1	<0.1%
-1018.245...	1	<0.1%
-1015.697...	1	<0.1%
-967.5947...	1	<0.1%
-964.7986...	1	<0.1%
-952.8311...	1	<0.1%

Colonne Billing Amount : La colonne en question présente des valeurs négatives. Étant donné que cette colonne représente le montant des frais facturés pour les services de santé reçus par le patient, il est impératif, dans le contexte métier, de définir clairement une règle pour valider ou invalider la présence de ces valeurs négatives. Une valeur négative pourrait, par exemple, indiquer une somme que le patient reste devoir, c'est-à-dire un montant impayé .

SMALLEST VALUES		
13	14	<0.1%
14	18	<0.1%
15	28	<0.1%
16	24	<0.1%
17	32	<0.1%
18	772	1.4%
19	805	1.5%
20	750	1.4%
21	822	1.5%
22	817	1.5%
23	790	1.4%
24	837	1.5%
25	836	1.5%
26	815	1.5%
27	786	1.4%

Colonne Age : Il est également observé que l'ensemble de données contient des informations sur des patients mineurs. Cependant, ces enregistrements présentent aussi un montant facturé (*billing amount*). Or, un enfant ou une personne mineure n'a légalement pas le droit de signer des documents ou de s'engager à payer des sommes, notamment pour des factures de soins.

c) Cohérence et logique métier :

Cette partie permet d'évaluer si les relations entre les colonnes sont cohérentes et logiques du point de vue métier, un aspect qui constitue le principal point faible du dataset.

Anomalie Détectée	Colonnes Concernées	Exemples Concrets / Preuves	Impact Projet
Rupture Médicale	Medication vs Medical Condition	Patient avec Asthme reçoit de la Pénicilline. Patient avec Cancer reçoit de l'Aspirine.	DANGER. Risque d'iatrogénie. Impossible d'entraîner une IA de recommandation.
Rupture Diagnostique	Test Results vs Medical Condition	Patient Cancer a un test Normal. Patient sain a un test Anormal. (Corrélation 0.00).	Rend les tests inutiles. Taux de Faux Positifs/Négatifs aberrants.
Rupture Assurantielle	Insurance vs Age	Patient de 15 ans couvert par Medicare (réservé aux +65 ans).	Refus de remboursement garantis dans la réalité.

Rupture Financière	Billing vs Admission	Une Urgence lourde facturée 200\$. Une visite de contrôle facturée 50k\$.	Impossible d'analyser la rentabilité par Medical condition.
Rupture Spatiale	Room Number vs Date	"Surbooking" probable (Plusieurs patients chambre 101 le même jour).	Gestion des lits impossible.

→ Exemple d'illustrations depuis le dataset source :

Healthcare Dataset		
Data Card	Code (203)	Discussion (14)
Hypertension	Medicare	Lipitor
Diabetes	Cigna	Penicillin
Asthma	UnitedHealthcare	Lipitor
Cancer	UnitedHealthcare	Paracetamol
Obesity	Blue Cross	Aspirin
Arthritis	UnitedHealthcare	Paracetamol
Obesity	Cigna	Paracetamol
Hypertension	Blue Cross	Aspirin
Asthma	Cigna	Penicillin
Asthma	Blue Cross	Aspirin
Asthma	Aetna	Lipitor
Arthritis	Aetna	Lipitor
Asthma	Aetna	Lipitor

Ces données récupérées depuis la source montre l'exemple cité dans la première ligne du tableau , Elle explique l' incohérence entre les colonnes **Medication** et **Medication Condition**. Les traitements prescrits sont en totale contradiction avec l'état de santé du patient, rendant toute modélisation prédictive ou prescriptive (e.g., IA de recommandation) inutilisable. et dangereuse.

d) Unicité et cardinalité :

Cette partie présente l'analyse de l'unicité et de la cardinalité des colonnes, afin de vérifier la présence d'identifiants uniques et de comprendre la distribution des valeurs au sein du dataset.

Anomalie Détectée	Colonnes Concernées	Exemples Concrets / Preuves	Impact Projet
-------------------	---------------------	-----------------------------	---------------

Hyper-Fragmentation	Doctor	40 341 médecins pour 55k visites. (Ratio 1.3 patient/médecin).	Absurde. Un hôpital a ~200 médecins, pas 40k. Gestion RH impossible.
Dispersion Mondiale	Hospital	39 876 hôpitaux. Presque 1 hôpital différent par patient.	Impossible de comparer la performance des hôpitaux (Benchmarking).
Doublons Clients	Name	~5 500 noms répétés (sur 55k).	Nécessite un dédoublonnage intelligent (Fuzzy Matching) en Phase 3.

e) Completeness :

Manque-t-il des données ?

- + **Observation** : 100% de remplissage partout (0 Null).
- + **Analyse** : C'est "trop beau pour être vrai". Dans la vraie vie, il manque toujours des numéros de téléphone ou des groupes sanguins.
- + **Conclusion** : Confirme la nature synthétique du fichier. C'est le seul point qui ne nécessite pas de "nettoyage", mais qui nécessite de la vigilance.

f) Distribution :

Les valeurs sont-elles réparties naturellement ?

- + **Le Syndrome de l'Uniformité** :
 - *Gender* : 50/50 parfait.
 - *Admission Type* : 33/33/33 parfait.
 - *Date* : Activité plate sur 5 ans (Pas de pics en hiver, pas de creux le dimanche).
 - *Medical Condition* : Autant de Cancers que d'Obésité.
- + **Impact** : Empêche toute prévision (Forecasting) et dimensionnement des équipes.

3. Exploration manuelle

Au-delà du profilage automatisé, nous avons développé des scripts Python spécifiques (Pandas) pour tester la *cohérence métier* et la *logique fonctionnelle* des données. Cette démarche vise à détecter des anomalies complexes invisibles aux outils standards. Toute l'analyse est faite dans **02_Profilage_Exploration_manuelle.ipynb**.

3.1. Analyse Préliminaire et Structurale

Avant d'investiguer la cohérence médicale, nous avons audité l'intégrité structurelle du fichier à l'aide de commandes standards pour valider les formats et les plages de valeurs admissibles.

- **Audit de la Structure** (*df.info()*) : Nous avons vérifié les types de données des 55 500 entrées. Les colonnes temporelles (*Date of Admission*, *Discharge Date*) étant chargées en format object (string), nous avons dû les convertir explicitement en datetime pour permettre les calculs de durée.

```
... <class 'pandas.core.frame.DataFrame'>
RangeIndex: 55500 entries, 0 to 55499
Data columns (total 15 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Name                   55500 non-null object
1   Age                    55500 non-null int64
2   Gender                 55500 non-null object
3   Blood Type             55500 non-null object
4   Medical Condition      55500 non-null object
5   Date of Admission      55500 non-null object
6   Doctor                 55500 non-null object
7   Hospital               55500 non-null object
8   Insurance Provider     55500 non-null object
9   Billing Amount          55500 non-null float64
10  Room Number            55500 non-null int64
11  Admission Type          55500 non-null object
12  Discharge Date         55500 non-null object
13  Medication              55500 non-null object
14  Test Results           55500 non-null object
dtypes: float64(1), int64(2), object(12)
memory usage: 6.4+ MB
```

Changer type des attributs

```
# Convert dates
df["Date of Admission"] = pd.to_datetime(df["Date of Admission"])
df["Discharge Date"] = pd.to_datetime(df["Discharge Date"])
```

- **Contrôle de Complétude** (*df.isna()*) : L'analyse a révélé un taux de remplissage de 100% sur l'ensemble des 15 colonnes.

	missing_count	missing_percent
Name	0	0.0
Age	0	0.0
Gender	0	0.0
Blood Type	0	0.0
Medical Condition	0	0.0
Date of Admission	0	0.0
Doctor	0	0.0
Hospital	0	0.0
Insurance Provider	0	0.0
Billing Amount	0	0.0
Room Number	0	0.0
Admission Type	0	0.0
Discharge Date	0	0.0
Medication	0	0.0
Test Results	0	0.0

- **Détection des Doublons Techniques** : Nous avons identifié 11 000 enregistrements dupliqués sur la clé composite *[Name, Date of Admission]*, signalant que le même patient est enregistré plusieurs fois pour la même admission.

Duplicates patients

```

duplicates = df[df.duplicated(
    subset=["Name", "Date of Admission"], keep=False
)]
duplicates.shape
(11000, 15)

```

```

duplicates_sorted = (
    df[df.duplicated(subset=["Name", "Date of Admission"], keep=False)]
    .sort_values(by=["Name", "Date of Admission"])
)

duplicates_sorted.head(20)

```

	Name	Age	Gender	Blood Type	Medical Condition	Date of Admission	Doctor	Hospital	Insurance Provider	Billing Amount	Room Number	Admission Type
17083	AARon smITh	79	Male	A-	Cancer	2019-11-21	Gina Jacobs	Weber-Warren	Medicare	21879.766348	155	Emergency
54393	AARon smITh	81	Male	A-	Cancer	2019-11-21	Gina Jacobs	Weber-Warren	Medicare	21879.766348	155	Emergency
3040	AARon smITh	47	Female	B-	Cancer	2021-01-10	Cynthia Villanueva	Montes Case and	Medicare	10602.077185	108	Urgent

- **Validation des Domaines de Valeurs (Range Checks)** :

- + **Âge** : Recherche de valeurs aberrantes (négatives ou > 120 ans). Le script `age_anomalies` n'a retourné aucun résultat, confirmant que l'âge est borné entre 13 et 89 ans.

Âge incohérent

(Age < 0 ou Age > 120)

```

age_anomalies = df[(df["Age"] < 0) | (df["Age"] > 120)]
age_anomalies.shape
(0, 15)

```

- + **Genre** : Vérification des incohérences biologiques (ex: Homme + Grossesse). Le test n'a relevé aucune anomalie de ce type.

Gender incohérent

Par ex: Gender = "Male" + Medical Condition = "Pregnancy"

```

gender_male_anomalies = df[
    (df["Gender"] == "Male") &
    (df["Medical Condition"] == "Pregnancy")
]
gender_male_anomalies.shape
(0, 15)

```

- + **Numéros de Chambre** : Test de validité sur la plage logique (ex: < 0 ou > 1000). Aucun numéro hors norme n'a été détecté techniquement, bien que leur usage soit incohérent temporellement.

```
Room Number incohérent

room_anomalies = df[
    (df["Room Number"] <= 0) |
    (df["Room Number"] > 10000)
]
room_anomalies.shape

(0, 16)
```

3.2. Synthèse des Analyses Effectuées

Nous avons soumis le dataset à une batterie de 20 tests de cohérence répartis sur 4 dimensions :

- **Validité Clinique** :
 - + Compatibilité *Âge vs Medical condition* (ex: Hypertension chez les nourrissons).
 - + Compatibilité *Genre vs Medical condition* (ex: Grossesse chez les hommes).
 - + Cohérence *Medical Condition vs Résultat de Test* (ex: Diabète mais test Normal).
 - + Cohérence *Medical condition vs Médicament* (Adéquation du traitement).

Exemple : Cohérence *Médication condition vs Résultat de Test* (ex: présence Diabète mais le test Results est Normal).

Test Results vs Medical Condition

↑
↓
✎
🗑️
⋮

Exemple: Medical Condition = "Diabetes" & Test Results = "Normal"

▶

```

incoherent_tests_diab = df[
    (df["Medical Condition"] == "Diabetes") &
    (df["Test Results"] == "Normal")
]
incoherent_tests_diab.shape
    
```

...
(3090, 16)

```
incoherent_tests_diab.head()
```

lood Type	Medical Condition	Date of Admission	Doctor	Hospital	Insurance Provider	Billing Amount	Room Number	Admission Type	Discharge Date	Medication	Test Results	Length of Stay
AB+	Diabetes	2020-05-04	Heather Smith	Nelson-Phillips	Cigna	36992.273688	413	Urgent	2020-05-13	Aspirin	Normal	
B+	Diabetes	2024-02-06	Jonathan Drake	Clark Brown, and Myers	UnitedHealthcare	35776.815111	489	Emergency	2024-02-10	Penicillin	Normal	
A+	Diabetes	2022-12-10	Jason Price	Henderson-Taylor	UnitedHealthcare	21772.341399	459	Elective	2022-12-31	Ibuprofen	Normal	

- **Intégrité Financière :**

- + Détection des montants de facturation négatifs ou nuls.
- + Corrélation *Durée de Séjour vs Facture*.
- + Éligibilité *Âge vs Assurance* (Medicare pour les < 65 ans).

Exemple : analyse de la facture par rapport au durée de séjour

Montant de facturation incohérent avec la durée de séjour

```
billing_stay_anomalies = df[
    (df["Length_of_Stay"] > 30) &
    (df["Billing Amount"] < df["Billing Amount"].quantile(0.1))
]
billing_stay_anomalies.shape
```

(0, 16)

- **Logistique & Temporel :**

- + Chronologie (*Date Sortie > Date Admission*).
- + Détection des séjours impossibles (> 365 jours ou futurs).
- + Collisions spatiales (Surbooking des chambres).
- + Calcul des réadmissions suspectes (< 7 jours).

Exemple : Chronologie (*Date Sortie > Date Admission*)

Date incohérente (sortie avant admission)

```
▶ date_anomalies = df[df["Discharge Date"] < df["Date of Admission"]]
date_anomalies.shape
```

... (0, 15)

- **Qualité des Données & Identité :**

- + Dédoublonnage sur clé composite (*Nom + Date*).
- + Analyse de la charge médecin (Volume de patients anormal).
- + Vérification des formats de texte (Casse, Suffixes commerciaux).

Exemple : Vérification des formats de texte (Casse, Suffixes commerciaux)

La Qualité des Textes (Problèmes de format)

casse aléatoire : Compter combien de noms contiennent des majuscules au milieu du mot.

les noms d'hôpitaux business : Chercher les suffixes "LLC" ou "Inc" qui ne devraient pas être là pour un hôpital.

```
# Détection de casse irrégulière (lettre majuscule au milieu d'un nom)
# Regex : une minuscule suivie d'une majuscule
irregular_case = df[df["Name"].str.contains(r'[a-z][A-Z]', regex=True)]
print(f"Noms avec casse mixte suspecte : {irregular_case.shape[0]}")

# Détection de suffixes commerciaux dans les hôpitaux
commercial_hospitals = df[df["Hospital"].str.contains(r' LLC| Inc| Ltd', regex=True)]
print(f"Hôpitaux avec noms commerciaux (LLC, Inc...) : {commercial_hospitals.shape[0]}")
```

Noms avec casse mixte suspecte : 27141

Hôpitaux avec noms commerciaux (LLC, Inc...) : 2305

4. Plan de Redressement & Matrice d'Impact Métier

Suite aux analyses exploratoires (automatisées et manuelles), nous avons établi un plan de nettoyage rigoureux. Afin de garantir une architecture saine et maintenable, nous avons séparé les règles de correction en deux catégories distinctes : les **Règles Techniques** (garantissant l'intégrité de la donnée) et les **Règles Métier** (garantissant la cohérence fonctionnelle).

Ce plan respecte les 6 piliers de la Gouvernance des Données : **Complétude, Unicité, Exactitude, Validité, Actualité, Cohérence**.

4.1. Le Plan de Redressement Technique (Data Quality)

Objectif : Rendre la donnée manipulable, propre et standardisée pour les systèmes informatiques.

ID	Pilier	Anomalie / Risque	Priorité	Action Corrective (Logique d'Exécution)
T01	Complétude	Données Manquantes Critiques Absence de Nom ou de Date.	P1	1. Suppression pure et simple. Une ligne sans patient ni date est inexploitable.
T03	Exactitude	Formats Hétérogènes Casse aléatoire ("dAvId"), espaces en trop.	P3	2. Standardisation (AVANT Dédoublonnage) : Application du "Title Case" et "Trim" pour normaliser les textes.
T04	Exactitude	Pollution Textuelle Suffixes juridiques ("LLC", "Inc").	P3	3. Nettoyage Regex : Suppression des motifs commerciaux. "Hopital A LLC" devient "Hopital A".
T02	Unicité	Doublons Techniques Même patient enregistré plusieurs fois.	P1	4. Dédoublonnage Strict : Suppression sur la base propre [Nom + Date]. Maintenant efficace grâce à T03 & T04.

T05	Validité	Valeurs Aberrantes Âge négatif ou > 120 ans.	P2	5. Sanity Check : Remplacement par NaN pour ne pas fausser les moyennes.
T06	Validité	Conformité des Listes Groupe sanguin hors norme.	P3	6. Standardisation : Remplacement par "Unknown".

4.2. Le Plan de Redressement Métier (Business Logic)

Objectif : Garantir que la donnée a du sens pour les médecins, les comptables et les analystes.

ID	Pilier	Anomalie / Incohérence	Priorité	Action Corrective (Règle Métier)
M01	Validité	Incohérence Financière Montants de facturation négatifs.	P1	Redressement : Conversion en valeur absolue (<code>abs()</code>). Hypothèse d'une erreur de signe comptable.
M02	Actualité	Chronologie Impossible Date de Sortie antérieure à la Date d'Admission.	P1	Filtrage : Exclusion des dossiers invalides. On ne peut pas calculer de durée de séjour négative.
M03	Actualité	Voyage dans le Temps Date d'Admission dans le futur (supérieure à la date du jour).	P1	Filtrage : Exclusion des lignes. Ce sont des erreurs de saisie ou des tests.

M04	Cohérence	Logique Assurantielle Patient de moins de 65 ans sous Medicare (interdit sauf exception rare).	P2	Imputation : Remplacement automatique par "Blue Cross" (Assurance standard par défaut).
M05	Cohérence	Incompatibilité Clinique (1) Médicament contre-indiqué pour la maladie (ex: Asthme + Pénicilline).	P2	Flagging (Alerte) : Création d'une colonne <u>Alert_Medication</u> . Note : On ne supprime pas la donnée médicale brute par éthique.
M06	Cohérence	Incompatibilité Clinique (2) Résultat de test contradictoire (ex: Diabète déclaré mais Test Normal).	P2	Flagging (Alerte) : Création d'une colonne <u>Alert_Test</u> .
M07	Cohérence	Anomalie Facturation/Séjour Séjour < 1 jour facturé > 20k\$ OU Séjour > 30 jours facturé < 500\$.	P2	Flagging (Alerte) : Création d'une colonne <u>Alert_Billing_Anomaly</u> pour audit financier.

4.3. Matrice d'Impact Métier

Cette matrice justifie l'investissement dans le nettoyage des données.

Domaine Impacté	Risque si non corrigé	Gain après nettoyage (Phase 3)
-----------------	-----------------------	--------------------------------

Finance	Perte de Revenus / Erreur Comptable Les factures négatives faussent le Chiffre d'Affaires total.	Fiabilité Comptable Calcul exact du CA et de la rentabilité par hôpital.
Légal	Fraude à l'Assurance Déclarer des patients < 65 ans sous Medicare entraîne des rejets de remboursement massifs.	Conformité Dossiers "propres" prêts à être envoyés aux assureurs sans risque de rejet.
Sécurité Patient	Risque Médical (Iatrogénie) Analyser des traitements incohérents (ex: Aspirine pour Cancer) fausse les études cliniques.	Sécurité des Analyses Les dossiers incohérents sont isolés (Flaggés) et exclus des études d'efficacité.
Opérationnel	Gestion des Lits Impossible Les dates incohérentes et doublons empêchent de savoir combien de lits sont réellement occupés.	Optimisation Calcul précis de la Durée Moyenne de Séjour (DMS) et du taux d'occupation.