

Phase 4 : Validation

1. Objectif du Quality Gate

Après le nettoyage technique et métier (Phase 3), nous avons instauré une **barrière de qualité stricte** avant la promotion des données vers la couche finale (*Gold*). Cette étape n'a pas pour but de modifier les données, mais de **certifier leur conformité** par rapport à un contrat d'interface défini. Elle utilise le script `04_validation_great_expectation.ipynb`

Outil utilisé : Framework *Great Expectations* (GX).

2. Stratégie de Validation (Les 6 Piliers de la Qualité)

Nous avons configuré une suite de **15 règles de validation** (*Expectation Suite*) couvrant les dimensions fondamentales de la qualité des données.

#	Pilier (Qualité)	Champ Cible	Règle Technique	Explication du Contrôle
1	Structure	Table entière	<code>row_count_between</code>	Volume : Vérifie que le fichier n'a pas subi de perte massive de données (minimum 30 000 lignes attendues).
2	Unicité	Name + Date	<code>compound_columns_unique</code>	Anti-Doublons : Vérifie qu'il est impossible d'avoir le même patient admis deux fois le même jour.
3	Complétude	Name	<code>values_not_null</code>	Obligatoire : Rejette tout enregistrement où le nom du patient serait vide.
4	Complétude	Date Admission	<code>values_not_null</code>	Obligatoire : Rejette tout enregistrement sans date d'entrée.
5	Exactitude	Hospital	<code>not_match_regex</code>	Nettoyage : Confirme que les suffixes parasites ("LLC", "Inc") ont bien été supprimés par le script de nettoyage.

6	Exactitude	Doctor	match_regex	Format : Vérifie que le nom du médecin respecte la convention (Commence par une Majuscule).
7	Validité	Age	values_between	Logique : L'âge doit être réaliste (entre 0 et 120 ans). Rejette les valeurs négatives.
8	Validité	Billing Amount	values_between	Financier : Le montant de la facture doit être strictement positif.
9	Validité	Blood Type	values_in_set	Référentiel : Le groupe sanguin doit être dans la liste officielle (A+, O-, etc.) ou 'Unknown'.
10	Validité	Admission Type	values_in_set	Référentiel : Le type doit correspondre aux catégories métiers (Urgent, Emergency, Elective).
11	Validité	Gender	values_in_set	Référentiel : Le genre doit être normalisé (Male, Female).
12	Cohérence	Dates (Sortie vs Entrée)	pair_values_A > B	Chronologie : La Date de Sortie doit impérativement être postérieure à la Date d'Entrée.
13	Cohérence	Age	mean_between	Statistique : L'âge moyen global des patients doit se situer entre 30 et 60 ans (détection de biais).
14	Cohérence	Hospital	unique_count_betwe en	Diversité : Le nombre d'hôpitaux différents doit être cohérent (entre 10 et 50 000).
15	Actualité	Date Admission	values_between	Temporel : Aucune admission ne peut être enregistrée dans le futur (Date Max = Aujourd'hui).

3. Architecture du Pipeline de Validation

Le script Python orchestre la validation selon le flux suivant :

1. *Ingestion* : Lecture de la table `healthcare_silver` (nettoyée).

2. *Validation* : Le "Validator" passe les 50 000 lignes au crible des 15 règles.
3. *Checkpoint & Alerting* :
 - Génération d'un rapport HTML `index.html` (*Data Docs*) pour l'analyse détaillée.
 - Envoi d'une notification temps réel sur **Slack** (Webhook).
4. *Décision Automatique (Logic)* :
 - **SI Succès (100% Validé)** : Les données sont promues dans la table `healthcare_gold`.
 - **SI Échec** : Le pipeline s'arrête, aucun transfert vers Gold n'est effectué.

4. Résultats et Preuves de Fonctionnement

A. Le Rapport de Validation (Data Docs)

Le framework a généré un rapport HTML interactif prouvant la conformité des données et *accessible au port 8080*.

The screenshot shows the Great Expectations Data Docs interface. The top navigation bar includes the logo and the path: Home / Validations / default / __none__ / 2026-02-10T22:20:21Z. The main content area is titled "Expectation Validation Result" and includes a description: "Evaluates whether a batch of data matches expectations." On the left, there are "Actions" (Show All, Failed Only, How to Edit This Suite, Show Walkthrough) and a "Table of Contents" (Overview, Table-Level Expectations, Admission Type). The "Overview" section shows "Expectation Suite: default", "Data asset: None", and "Status: Succeeded" (highlighted with a red circle). The "Statistics" section shows: Evaluated Expectations: 15, Successful Expectations: 15, Unsuccessful Expectations: 0, Success Percent: 100%. Below this is a "Table-Level Expectations" table with columns: Status, Expectation, and Observed Value. The table contains one row: "Must have greater than or equal to 30000 rows." with an observed value of 49986.


Status	Expectation	Observed Value
	values must belong to this set: <code>Urgent</code> <code>Emergency</code> <code>Elective</code> .	0% unexpected
Age		
	values must be greater than or equal to <code>0</code> and less than or equal to <code>120</code> .	0% unexpected
	mean must be greater than or equal to <code>30</code> and less than or equal to <code>60</code> .	≈51.57904213
Billing Amount		

etc..

Observation : Toutes les règles sont respectées ("Success"). La règle d'unicité confirme que les 28 doublons identifiés avant correction ont bien été éliminés.


B. Système d'Alerte (Slack)

Intégration d'un Webhook Slack pour notifier l'équipe Data en temps réel.



Résultat : Le bot confirme le succès de la validation ("Success").

Avec un lien qui mène vers le data docs mis à jour :



5. Conclusion de la Phase

Grâce à ce dispositif, la table `healthcare_gold` ne contient que des données **certifiées, propres et uniques**. Elle est désormais prête à être connectée à l'outil de Dataviz (PowerBI) sans risque d'erreurs d'interprétation.

Vérification de présence des données dans la table `healthcare_gold` :

```
MariaDB [data_quality_db]> select * from healthcare_gold limit 3;
```

Name	Age	Gender	Blood Type	Medical Condition	Date of Admission	Doctor	Hospital	Insurance Provider	Billing Amount
Room Number	Admission Type	Discharge Date	Medication	Test Results	Length_of Stay	Alert_Billing_Anomaly	Alert_Test	Alert_Medication	Medication_Corrected
Bobby Jackson	30	Male	B-	Cancer	2024-01-31 00:00:00	Matthew Smith	Sons And Miller	Blue Cross	18856.28130597815
5 328	Urgent	2024-02-02 00:00:00	Paracetamol	Normal	2	0	0	0	Paracetamol
Leslie Terry	62	Male	A+	Obesity	2019-08-20 00:00:00	Samantha Davies	Kim	Blue Cross	33643.32728657788
5 265	Emergency	2019-08-26 00:00:00	Ibuprofen	Inconclusive	6	0	0	0	Ibuprofen
Danny Smith	76	Female	A-	Obesity	2022-09-22 00:00:00	Tiffany Mitchell	Cook	Aetna	27955.09607884245
6 205	Emergency	2022-10-07 00:00:00	Aspirin	Normal	15	0	0	1	Diet